

IFT-7026 Projet expérimental

Projet proposé par Luc Lamontagne et Thierry Badard

Étudiant : Justin-Joël Takodjou Djoko

Hiver 2026

Objectif du projet : Se familiariser avec les techniques de *génération augmentée par récupération* (RAG) et explorer les extensions de ce paradigme aux données géographiques.

Résumé : Les grands modèles de langue (LLM) représentent l'état de l'art dans plusieurs domaines de recherche comme l'analyse de texte, la génération d'images et la programmation automatique. Cependant, ces modèles présentent des limitations pour d'autres tâches, comme le raisonnement sur des entités géographiques. L'objectif de ce projet est d'évaluer dans quelle mesure le paradigme de la *génération augmentée par récupération* (en anglais *retrieval-augmented generation* - RAG) peut améliorer les performances des LLMs pour les tâches de raisonnement spatial utilisant des informations géographiques. Le RAG combine deux capacités : a) la récupération d'informations pertinentes à partir de sources externes et b) la génération d'une réponse en langage naturel à partir de ces nouvelles informations à l'aide d'un LLM. Bien que cette approche soit bien établie pour des données textuelles ou des images, les travaux visant à étendre le RAG aux données géographiques en sont à leurs débuts.

Ce projet est divisé en 2 phases. La première permettra à l'étudiant de se familiariser avec les principaux concepts du RAG et de mener une expérience pour comprendre comment mettre en œuvre cette approche à l'aide de bibliothèques logicielles et de constater les limites actuelles des RAG à traiter les relations spatiales dans les textes et ainsi à répondre à des questions nécessitant un raisonnement spatial. Pour ce faire, l'étudiant devra mener des expérimentations à partir d'un ensemble de ressources documentaires (ex. articles Wikipedia) et de questions à répondre, mobilisant des relations spatiales. Il réalisera une évaluation quantitative (par ex. justesse des réponses des LLMs) et qualitative (par ex., analyse des erreurs, qualité des informations récupérées) des résultats obtenus.

Dans la seconde phase, l'étudiant sera tout d'abord responsable de mener une étude sur les extensions géographiques du RAG. Il devra réaliser une revue de littérature qui lui permettra d'identifier les principaux axes de ce champ d'études et les pistes d'expérimentation potentielles. Les références fournies à la fin du présent sujet lui serviront de point de départ dans cette revue de la littérature scientifique. Il tâchera ensuite de mettre en œuvre une de

ces extensions et de mesurer en quoi elle améliore les performances du RAG mis en place dans la première partie du projet.

La nature des ressources complémentaires (ouvrages, articles, données) nécessaires à ce travail sur le RAG géospatial sera discutée et priorisée conjointement avec les professeurs afin de déterminer rapidement la portée des expérimentations à mener durant la session.

Travaux à effectuer :

1. Effectuer une synthèse des articles et ouvrages donnés en référence. Ceux-ci constituent le point de départ de l'état de l'art que l'étudiant devra mener dans ses travaux.
2. À partir du contenu du livre de Kimothi (2025) et de diverses ressources RAG disponibles sur le site web HuggingFace (voir liste de références), reproduire différentes expériences en utilisant un corpus de texte et d'une liste de questions de nature géospatiale à répondre.
3. Comparer les performances de différents modèles pour cette tâche (à sélectionner conjointement avec les professeurs) – au minimum les modèles *gpt-oss* et *Deepseek-r1-14B*. Analyser et commenter les résultats obtenus avec une configuration de base pour chaque modèle. Comparer les résultats obtenus avec et sans récupération RAG.
4. Analyser l'impact des facteurs suivants sur la qualité des réponses des différentes configurations système : la taille des passages de textes (*chunks*), le nombre de passages conservés, la formulation des *prompts* et le choix du modèle d'encodage pour la récupération d'information. Rédiger un rapport intermédiaire qui présente les résultats.
5. Dresser un inventaire des approches et ressources recensées dans la littérature récente concernant les extensions du RAG à partir de données géospatiales. Décrire les modifications à apporter au pipeline RAG étudié précédemment afin d'y intégrer une de ces approches.
6. Sélectionner un jeu de données et étendre le pipeline RAG aux données géospatiales selon l'approche retenue. Évaluer les performances obtenues avec les modèles précédemment sélectionnés. Réaliser une analyse quantitative et qualitative des nouvelles configurations RAG. Rédiger un rapport final qui présente les résultats.
7. Proposer des pistes de recherche pour approfondir ce sujet.

Évaluation :

- Présentation orale de la synthèse des articles et travaux donnés en référence (15%)
- Production des expérimentations avec des données textuelles et analyse d'impact des différents facteurs (15%)
- Rapport préliminaire (mi-session) sur l'évaluation des modèles (35%)
 - o Description de la problématique et de la méthodologie de recherche (10%)
 - o Analyse quantitative des performances des différentes configurations RAG avec les modèles sélectionnés (15%)
 - o Analyse qualitative des différentes configurations RAG (10%)
- Rapport final sur l'extension du paradigme RAG à des données géospatiales, l'étude comparative des configurations et les pistes de recherche identifiées (35%)
 - o Description des nouveaux aspects RAG étudiés depuis la mi-session (10%)
 - o Analyse quantitative des configurations RAG et des aspects étudiés (15%)
 - o Analyse qualitative des configurations RAG et aspects étudiés (10%)

Livrables :

- Les jeux de données utilisés pour les expérimentations
- Le code utilisé et produit durant le projet
- Les rapports de mi-session et final.

Références (préliminaire) :

Jurafsky, D. and Martin, J. H. (2026) Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models, 3rd edition, Online manuscript, <https://web.stanford.edu/~jurafsky/slp3/>

Chapitres 7 : Large Language models

Chapitre 8 : Transformers

Chapitre 11 : Information retrieval and Retrieval-Augmented Generation

Kimothi, A. (2025) A Simple Guide to Retrieval Augmented Generation, Manning Publications, June 2025, 256 pages, ISBN : 978163343558

Nguyen, X.-S. (2024) Code a simple RAF from scratch, cours sur le site de HuggingFace, <https://huggingface.co/blog/ngxson/make-your-own-rag>

Roucher, A. (2025) Advanced RAG on HuggingFace documentation using LangChain, cours sur le site de HuggingFace, https://huggingface.co/learn/cookbook/advanced_rag

Paniego, S., (2025) Multimodal Retrieval-Augmented Generation (RAG) with document retrieval and vision language models, cours sur le site de HuggingFace,

https://huggingface.co/learn/cookbook/multimodal_rag_using_document_retrieval_and_vlms

- Kostis, D. S. E. (2025). Retrieval-Augmented Generation with Geospatial Search: Optimizing Spatial Data Retrieval through Embeddings and Vector Search. B. Sc. Thesis, National and Kapodistrian University of Athens.
- Yu, D., Bao, R., Mai, G., & Zhao, L. (2025). Spatial-rag: Spatial retrieval augmented generation for real-world spatial reasoning questions. arXiv preprint arXiv:2502.18470.
- Liang, J., Hou, S., Jiao, H., Qing, Y., Zhao, A., Shen, Z., ... & Wu, H. (2025). GeoGraphRAG: A graph-based retrieval-augmented generation approach for empowering large language models in automated geospatial modeling. *International Journal of Applied Earth Observation and Geoinformation*, 142, 104712.
- Bicakci, Y. S., Shingleton, J., & Basiri, A. (2025). Street-Level Geolocalization Using Multimodal Large Language Models and Retrieval-Augmented Generation. arXiv preprint arXiv:2509.01341.
- Ni, H., Liu, F., Ma, X., Su, L., Wang, S., Yin, D., ... & Liu, H. (2025). TP-RAG: Benchmarking Retrieval-Augmented Large Language Model Agents for Spatiotemporal-Aware Travel Planning. arXiv preprint arXiv:2504.08694.
- Luo, P., Lou, X., Zheng, Y., Zheng, Z., & Ermon, S. (2025). GeoEvolve: Automating Geospatial Model Discovery via Multi-Agent Large Language Models. arXiv preprint arXiv:2509.21593.