

Planification de lecture dirigée – IFT-7026

Université Laval

Hamza Alaoui

Superviseur: Prof. Mohamed Aymen Saied

Sujet : Automatisation intelligente de l'orchestration MLOps à l'aide de LLMs : Analyse et génération de pipelines Kubeflow

1. Objectif

Cette lecture dirigée vise à approfondir l'étude des défis opérationnels liés à la mise en production de modèles d'apprentissage automatique, en se concentrant sur l'automatisation de l'orchestration MLOps à l'aide des LLMs. Les objectifs sont :

- Étudier les pratiques actuelles en MLOps : pipelines, frameworks (Kubeflow, MLflow), outils QA.
- Identifier les odeurs de performance récurrentes (performance smells) dans des projets open source.
- Analyser la capacité des LLMs à automatiser la génération de pipelines Kubeflow à partir de descriptions en langage naturel.
- Développer une preuve de concept de génération automatique de pipelines KFP avec validation via outils QA (Pylint, KubeLinter).
- Présenter les bénéfices, limites, et perspectives de l'approche pour la recherche et l'industrie.

2. Contenu et Activités

Les travaux porteront sur les phases suivantes :

- Phase 1 — Revue de littérature et analyse empirique
 - Panorama des frameworks MLOps : Kubeflow, TFX, MLflow
 - Études des performance smells
 - Détection des performance smells dans des dépôts GitHub avec SonarQube, KubeLinter, etc.

- Phase 2 — Automatisation avec LLM
 - Construction d'un dataset de prompts et pipelines Kubeflow
 - Fine-tuning d'un LLM (ex. Qwen2.5) pour la génération de pipelines KFP
 - Évaluation (syntaxique, sémantique, opérationnelle) avec outils QA
- Phase 3 — Synthèse et perspectives
 - Comparaison de pipelines manuels vs générés automatiquement
 - Propositions pour intégrer cette approche dans les CI/CD
 - Discussion sur les limites et pistes futures

3. Évaluation

Composante	Pondération
Livrable 1 – Revue de littérature + analyse empirique (rapport)	30%
Présentation orale des approches d'automatisation (1h)	20%
Livrable 2 – Développement de l'approche + documentation	30%
Présentation finale du projet et résultats	20%

4. Échéancier

Étape	Date cible
Début de la lecture dirigée	Septembre 2025
Livrable 1 (analyse + synthèse)	Fin Octobre 2025
Présentation intermédiaire	Mi-Novembre 2025
Livrable 2 (génération + tests)	Fin-Novembre 2025
Présentation finale	Fin décembre 2025

5. Références principales

- C. Meng, C. Wang, C. Xu, et al., “Coulter: Unified programming of ai workflows,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2020, pp. 2863–2873. doi: 10.1145/3394486.3403390.
- D. Sculley, G. Holt, D. Golovin, et al., “Hidden technical debt in machine learning systems,” *Advances in Neural Information Processing Systems (NeurIPS)*, 2015. [Online]. Available: <https://proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcaf2674f757a2463eba-Paper.pdf>.
- N. Esfahani, A. Sarma, and B. Vasilescu, “Identifying and classifying pipeline smells in data science projects,” *Empirical Software Engineering*, vol. 27, no. 6, p. 143, 2022. doi: 10.1007/s10664-02210111-2.
- M. Vitui and W. Chen, “Llm-based self service for it operations on openshift,” *arXiv preprint arXiv:2501.12461*, 2025. [Online]. Available: <https://arxiv.org/abs/2501.12461>.
- R. Bommasani, D. A. Hudson, E. Adeli, et al., “On the opportunities and risks of foundation models,” *arXiv preprint arXiv:2108.07258*, 2021. [Online]. Available: <https://arxiv.org/abs/2108.07258>.
- Official documentation: Kubeflow (<https://www.kubeflow.org>), MLflow (<https://mlflow.org>), TFX (<https://www.tensorflow.org/tfx>), SonarQube (<https://docs.sonarsource.com>), KubeLint (<https://docs.kubelinter.io>)